# Classificação Automática de Alertas de Segurança num SOC

Tomás Ladeiro Domingues | 1231443

## 01

### PROBLEMA

Descrição do problema a apresentar

## 02

### OBJETIVOS

Objetivos a serem alcançados

## 03

### ANÁLISE TEÓRICA

Análise introdutória aos conceitos chave

## 04

### TRABALHOS RELACIONADOS

Trabalhos existentes relacionados com o problema

## 05

### FERRAMENTAS DE TRABALHO

Comparação e análise de possíveis ferramentas a utilizar.

# INTRODUÇÃO

A gestão eficiente de alertas de segurança é um desafio constante nos Centros de Operações de Segurança (SOC).

O volume elevado de alertas e a necessidade de identificar ameaças rapidamente tornam o processo de triagem inicial fundamental para a eficácia de um SOC.

Este trabalho tem como objetivo principal desenvolver um programa independente capaz de automatizar a triagem de alertas de segurança em um ambiente SOC.

# 01

# PROBLEMA

## Análise Manual

A triagem inicial de alertas depende da inspeção manual, o que torna o processo demorado e suscetível a erros humanos.

## Tempo de Resposta

A análise manual aumenta o tempo de deteção (MTTD) e o tempo de resposta (MTTR), permitindo que ameaças permaneçam indetetáveis por mais tempo.

## Sobrecarga de Alertas

Os analistas lidam com um volume excessivo de alertas, dificultando a priorização e aumentando o risco de não detetar ameaças críticas.

### Perda de Ameaças

A abordagem reativa aumenta o risco de perder ameaças importantes devido à sobrecarga de alertas e falhas na triagem.

### Fadiga dos Analistas

A sobrecarga de trabalho provoca fadiga nos analistas, reduzindo a eficácia e a precisão na triagem dos alertas.

### Fragilidade na Segurança

A análise manual compromete a postura de segurança da organização, tornando-a mais vulnerável a ataques e riscos de brechas.

# 02

# OBJETIVOS

# Objetivos do Estudo

**Automatizar a triagem de alertas de segurança em SOCs.**

## Pesquisa e Análise

Realizar uma revisão de literatura sobre automação e Machine Learning em SOCs.

## Integração com SIEM

Desenvolver e ligar o modelo de ML ao SIEM e outras fontes de dados.

## Avaliação de Modelos

Testar e avaliar a eficácia do modelo de ML.

**01**

- Identificar ferramentas e métodos de automação usados em SOCs.
- Estudar modelos de ML aplicados à triagem de alertas.

**02**

- Compilar datasets para treinar o modelo de Machine Learning.
- Implementar ingestão de dados em tempo real a partir de um SIEM.

**03**

- Criar um dashboard para feedback dos analistas sobre o modelo.
- Reduzir falsos positivos em triagem de alertas de segurança.

# 03

# ANÁLISE TEÓRICA

Centros de Operações de Segurança (SOC)

# RESPONSABILIDADES PRINCIPAIS

SOC

01

## PREVENIR

Prevenir incidentes com medidas proativas (scans e análises).

02

## MONITORIZAR

Monitorizar, detetar e analisar intrusões.

03

## RESPONDER

Responder a incidentes confirmados e coordenar recursos.

04

## INFORMAR

Informar stakeholders sobre incidentes, tendências e ameaças emergentes.

# ESTRUTURA p/ NÍVEIS

## TRIAGEM

Revisão inicial de alertas, validação e categorização.

1

2

## RESPOSTA A INCIDENTES

Análise aprofundada, resposta a incidentes complexos.

3+

## ANÁLISE DE AMEAÇAS

Caça a ameaças, avaliações de vulnerabilidades e testes de penetração.

# 03

# ANÁLISE TEÓRICA

Sistemas SIEM

# FUNCIONALIDADES PRINCIPAIS

Gerenciamento e Correlação de Eventos de Segurança

## RECOLHA

Recolha e agregação de logs (métodos push/pull).

## ANÁLISE

Análise e deteção de ameaças em tempo real.

## RELATÓRIOS

Relatórios e visualização para investigações detalhadas.

## NORMALIZAÇÃO

Uniformiza logs de diferentes fontes para consistência.

## CORRELAÇÃO

Liga eventos dispersos para detetar padrões maliciosos.

## AUTOMAÇÃO

Gera alertas e notifica em tempo real sobre incidentes.

# 03

# ANÁLISE TEÓRICA

Machine Learning (ML)

# PRINCIPAIS TÉCNICAS UTILIZADAS

## MACHINE LEARNING

Automatiza triagem de alertas, aumenta precisão, reduz falsos positivos e melhora a eficiência

### SUPERVISIONADA

Usa dados rotulados para treinar modelos, como Random Forest.

### NÃO SUPERVISIONADA

Agrupa dados sem rótulos, útil para identificar padrões desconhecidos e anomalias em grandes volumes de dados.

### REFORÇO

Modelos aprendem continuamente interagindo com o ambiente, adaptando-se a padrões emergentes.

# DIFICULDADES

## DESAFIOS

Overfitting ocorre quando o modelo memoriza dados específicos; underfitting, quando não captura padrões essenciais. Ambos comprometem resultados.

## DEPENDÊNCIAS

Modelos baseiam-se em dados históricos para aprendizado; datasets limitados ou desatualizados afetam a capacidade de detectar novas ameaças.

# MODELOS

## ÁRVORES DE DECISÃO

Simples, interpretáveis, mas propensas a overfitting.

## CLASSIFICADORES ENSEMBLE

Random Forest e XGBoost; maior precisão e robustez.

## Naive Bayes

Rápido e eficiente, mas assume independência entre variáveis.

# 03

# TRABALHOS RELACIONADOS

# OUTROS TRABALHOS

| AUTOR | MODELOS USADOS | MAIOR PRECISÃO | DESCRIPTION |
|---|---|---|---|
| **Ghafir et al. (2018)** | Decision Tree, SVM, KNN, Ensemble | **84,8%** | Módulos de deteção baseados em blacklist requerem atualizações contínuas; precisão inferior. |
| **Brogi e Tong (2016)** | Nenhum modelo de ML utilizado | **NÃO CALCULADO** | Método de Information Flow Tracking; FPR elevado. |
| **Giura e Wang (2012)** | Nenhum modelo de ML utilizado | **NÃO CALCULADO** | Requer conhecimento significativo para configurar o mecanismo. |
| **Sopan et al. (2019)** | Random Forest | **98,5%** | Decisões pós-alerta não automatizadas; dependem de especialistas. |
| **Farooq e Otaibi (2018)** | SVM, Random Forest | **NÃO CALCULADO** | Deteção de anomalias formal com One-Class SVM; sem resultados experimentais baseados em ML. |

| AUTOR | MODELOS USADOS | MAIOR PRECISÃO | OBSERVAÇÕES |
|---|---|---|---|
| **Sethi et al. (2020)** | Deep Q-network | **96,12%** | Modelo proposto deteta APTs. |
| **Nila, Apostol, e Patriciu (2020)** | ZeroR, OneR, NaiveBayes, SVM, J48, RF | **95,5%** | FPR do modelo não discutido pelos autores. |
| **Chandra, Challa, e Pasupuleti (2016)** | NaiveBayes | **87%** | FPR do modelo não discutido pelos autores. |
| **Saini et al. (2023))** | Random Forest, XGBoost | **99,91%** | Datasets usados podem não conter cenários de ataque mais recentes. |
| **Ali, Shah, e ElAffendi (2024)** | Random Forest, XGBoost | **99,6%** | Elevado uso de recursos; dataset gerado em ambientes controlados. |

# 04

# FERRAMENTAS DE TRABALHO

# SIEMs

## QRADAR

- Integração profunda com o ecossistema IBM, incluindo SOAR e ferramentas de automação.
- Deteção avançada de ameaças baseada em anomalias.
- Arquitetura modular e escalável, ideal para empresas de todos os tamanhos.
- Suporte a infraestruturas modernas, incluindo ambientes híbridos e nativos da nuvem.

## SPLUNK

- Focado em análises em tempo real e processamento de grandes volumes de dados.
- Ideal para caça a ameaças e gestão de conformidade.
- Extensa integração com ferramentas de terceiros e suporte a personalização.
- Oferece dashboards predefinidos e alertas personalizados no Splunk Enterprise Security (ES).

## LOGRHYTHM

- Fortemente orientado para conformidade (GDPR, HIPAA, PCI-DSS).
- Deteção de ameaças baseada em machine learning e anomalias comportamentais.
- Gestão do ciclo de vida de ameaças com fluxos de trabalho estruturados.
- Integração fluida com ferramentas externas e dashboards centralizados.

# FERRAMENTAS DE TICKETING

## QRADAR SOAR

- Automação com playbooks para respostas consistentes e rápidas.
- Gestão de casos com rastreamento centralizado de incidentes, evidências e comunicações.
- Integração com EDRs e serviços na nuvem para maior eficiência na resolução de incidentes.

## JIRA

- Ferramenta intuitiva e amplamente utilizada para gestão de incidentes em SOCs
- Ideal para equipas já familiarizadas com o ecossistema JIRA.
- Sistema de tickets fácil de usar para criação, atribuição e atualização de alertas.
- Integrações extensas com ferramentas de SIEM, mas funcionalidades de automação limitadas.

## SERVICENOW

- Solução versátil para gestão de serviços e incidentes em TI e cibersegurança.
- Módulo Security Incident Response (SIR) automatiza triagem e escalonamento de incidentes.
- Painéis interativos para monitorização e relatórios em tempo real.

# FRAMEWORKS DE ML

## SCIKIT-LEARN

- Biblioteca focada em algoritmos clássicos, como Random Forest e SVM.
- Ideal para tarefas de classificação, regressão e clusterização.
- Integração com pandas e NumPy para manipulação de dados eficiente.
- Ferramenta robusta para prototipagem rápida, mas limitada para deep learning

## TENSORFLOW

- Desenvolvido pelo Google, suporta machine learning e deep learning em larga escala
- Excelente para produção em ambientes móveis, edge computing e na nuvem.
- Ferramenta TensorBoard para monitorização de desempenho e ajustes

## PYTORCH

- Destaca-se em processamento de linguagem natural e visão computacional.
- Integração com ONNX e NumPy para maior compatibilidade e portabilidade.
- Versátil para pesquisa e experimentação, mas requer experiência adicional para produção.

# Benefícios da Automação no SOC

A automação no ambiente de um Centro de Operações de Segurança (SOC) traz benefícios significativos para a triagem de alertas e a gestão de incidentes. Um dos principais impactos está na redução da carga de trabalho e fadiga dos analistas, especialmente os de nível 1, que lidam com tarefas repetitivas e análise inicial de alertas. Este tipo de automação ajuda a priorizar ameaças críticas, permitindo que os analistas se concentrem em problemas de maior risco e importância.

Além disso, a automação melhora indicadores-chave como o Tempo Médio de Deteção (MTTD) e o Tempo Médio de Resposta (MTTR). Com a capacidade de identificar rapidamente ameaças reais e eliminar falsos positivos, o SOC aumenta a sua eficiência operacional e reduz o tempo que uma ameaça pode permanecer ativa. A priorização automática baseada em análise de dados em tempo real também garante que os alertas mais urgentes sejam tratados de forma ágil, fortalecendo a postura de segurança da organização.

# Diferenciação do Projeto

O projeto apresentado diferencia-se de outras abordagens existentes pela sua integração direta com dados em tempo real e sistemas já implementados, como SIEMs. Enquanto muitas soluções dependem de datasets estáticos, esta iniciativa utiliza dados dinâmicos diretamente do ambiente operacional, permitindo maior adaptabilidade e resultados mais precisos no contexto da organização.

Outro ponto de destaque é o desenvolvimento de uma dashboard personalizada, que não fornece apenas insights sobre a eficácia do modelo, mas também permite que os analistas forneçam feedback contínuo. Essa funcionalidade garante que o modelo seja continuamente ajustado para se adaptar a novas ameaças, tornando-o uma ferramenta mais eficaz e alinhada com as necessidades reais do SOC. Essa abordagem única combina flexibilidade, precisão e escalabilidade, tornando-a particularmente relevante.

# BIBLIOGRAPHIC REFERENCES


- Ghafir, I. *et al.* (2018) “Detection of advanced persistent threat using machine-learning correlation analysis,” *Future Generation Computer Systems*, 89, pp. 349–359. Available at: https://doi.org/10.1016/J.FUTURE.2018.06.055.

- Brogi, G. and Tong, V.V.T. (2016) “TerminAPTor: Highlighting advanced persistent threats through information flow tracking,” *2016 8th IFIP International Conference on New Technologies, Mobility and Security, NTMS 2016* [Preprint]. Available at: https://doi.org/10.1109/NTMS.2016.7792480.

- Giura, P. and Wang, W. (2012) “A context-based detection framework for advanced persistent threats,” *Proceedings of the 2012 ASE International Conference on Cyber Security, CyberSecurity 2012*, pp. 69–74. Available at: https://doi.org/10.1109/CYBERSECURITY.2012.16.

- Sopan, A. *et al.* (2019) “Building a Machine Learning Model for the SOC, by the Input from the SOC, and Analyzing it for the SOC,” *2018 IEEE Symposium on Visualization for Cyber Security, VizSec 2018* [Preprint]. Available at: https://doi.org/10.1109/VIZSEC.2018.8709231.

# BIBLIOGRAPHIC REFERENCES


- Farooq, H.M. and Otaibi, N.M. (2018) “Optimal machine learning algorithms for cyber threat detection,” *Proceedings - 2018 UKSim-AMSS 20th International Conference on Modelling and Simulation, UKSim 2018*, pp. 32–37. Available at: https://doi.org/10.1109/UKSIM.2018.00018.

- Sethi, K. *et al.* (2020) “A context-aware robust intrusion detection system: a reinforcement learning-based approach,” *International Journal of Information Security*, 19(6), pp. 657–678. Available at: https://doi.org/10.1007/S10207-019-00482-7.

- Nila, C., Apostol, I. and Patriciu, V. (2020) “Machine learning approach to quick incident response,” *2020 13th International Conference on Communications, COMM 2020 - Proceedings*, pp. 291–296. Available at: https://doi.org/10.1109/COMM48946.2020.9141989.

- Chandra, J.V., Challa, N. and Pasupuleti, S.K. (2016) “A practical approach to E-mail spam filters to protect data from advanced persistent threat,” *Proceedings of IEEE International Conference on Circuit, Power and Computing Technologies, ICCPCT 2016* [Preprint]. Available at: https://doi.org/10.1109/ICCPCT.2016.7530239.

# BIBLIOGRAPHIC REFERENCES


- Saini, N. *et al.* (2023) “A hybrid ensemble machine learning model for detecting APT attacks based on network behavior anomaly detection,” *Concurrency and Computation: Practice and Experience*, 35(28), p. e7865. Available at: https://doi.org/10.1002/CPE.7865.